

Guion para video

Basado en: presentacion Canva (Data Lakehouse + Delta Lake + Apache Spark). Duracion sugerida: 12-18 minutos. Lee en voz alta lo que dice TEXTO PARA DECIR y muestra en pantalla lo que dice MOSTRAR EN PANTALLA.

BLOQUE 0 - Introduccion (1 min) | Canva: diapositiva 1

TEXTO PARA DECIR:

Hola. En este video presento el laboratorio de Data Lakehouse con Apache Spark y Delta Lake, aplicado al caso empresarial RetailX. Implemente un pipeline completo con arquitectura Medallion (Bronze, Silver y Gold), procesamiento con PySpark, persistencia en Delta Lake y un dashboard en Power BI conectado a la capa Gold.

MOSTRAR EN PANTALLA:

- * Diapositiva 1 de Canva (portada: Data Lakehouse + Delta Lake + Apache Spark)
- * Explorador de archivos: carpeta practicaBD/data-lakehouse/lakehouse

BLOQUE 1 - Problema RetailX y objetivos (2 min) | Canva: diapositivas 2 y 3

TEXTO PARA DECIR:

RetailX opera con fuentes heterogeneas: transacciones en CSV (ERP/POS), eventos web en JSON, telemetria IoT en XML. Eso genera reportes lentos, duplicados en KPIs y poca escalabilidad. Los objetivos del laboratorio son: diferenciar DW, Data Lake y Lakehouse; disenar pipeline Medallion; procesar millones de registros con Spark; y usar Delta Lake con ACID y versionado.

MOSTRAR EN PANTALLA:

- * Diapositiva 3 Canva: El problema Empresa RetailX
- * Carpeta data/: sales_raw.csv, sales_events.json, fleet_telemetry.xml
- * Diapositiva 2 Canva: Objetivos de aprendizaje (4 puntos)

BLOQUE 2 - DW vs Data Lake vs Lakehouse (1.5 min) | Canva: diapositiva 4

TEXTO PARA DECIR:

El Data Warehouse es rigido y costoso. El Data Lake guarda todo en bruto pero sin transacciones. El Lakehouse combina almacenamiento economico con Delta Lake: consistencia ACID, versionado y time travel sobre archivos Parquet.

MOSTRAR EN PANTALLA:

- * Diapositiva 4 Canva: DW vs Data Lake vs Lakehouse
- * Carpeta delta/gold/kpis_generales/_delta_log (muestra metadatos Delta)

BLOQUE 3 - Arquitectura Medallion (2 min) | Canva: diapositiva 5

TEXTO PARA DECIR:

Bronze: ingesta en crudo sin transformar (CSV, JSON, XML). Silver: limpieza, tipos correctos,

deduplicacion y calidad. Gold: KPIs y agregados de negocio listos para analisis y Power BI.

MOSTRAR EN PANTALLA:

- * Diapositiva 5 Canva: Bronze -> Silver -> Gold
- * Explorador: delta/bronze/sales_csv, sales_json, sales_xml
- * Explorador: delta/silver/sales_clean
- * Explorador: delta/gold/ (kpis, ventas por categoria, pais, mes, top productos)

BLOQUE 4 - Apache Spark (1 min) | Canva: diapositiva 6

TEXTO PARA DECIR:

Apache Spark procesa en memoria y en paralelo. Usamos PySpark en jobs separados por capa: Bronze, Silver, Gold, mas analisis de negocio y demostracion de time travel.

MOSTRAR EN PANTALLA:

- * Diapositiva 6 Canva: Apache Spark
- * Carpeta jobs/: 02_bronze.py, 03_silver.py, 04_gold.py, 06_analisis_negocio.py, 07_delta_time_travel.py

BLOQUE 5 - Laboratorio: Docker y generacion de datos (2.5 min) | Canva: diapositiva 7

TEXTO PARA DECIR:

Levantamos Docker Compose con red lakehouse-net y contenedor retailx_dataops_spark. Generamos datos de prueba: ventas en CSV (hasta 1 millon), eventos JSON y telemetria XML. El job 01b genera 1M tuplas con SparkSession llamada RetailX, como pide el laboratorio.

MOSTRAR EN PANTALLA:

- * Terminal: docker compose build y docker compose up -d
- * Terminal: docker ps (contenedor retailx_dataops_spark)
- * Terminal en contenedor: python jobs/run_pipeline.py --rows 10000
- * Consola mostrando: CSV generado, Bronze, Silver, Gold creados
- * Diapositiva 7 Canva: pasos 1 al 4 del laboratorio

BLOQUE 6 - Delta Lake: SQL y time travel (2 min) | Canva: diapositiva 8

TEXTO PARA DECIR:

Paso 5: consultamos CSV con Spark SQL (groupBy cliente, sum monto). Paso 6: escribimos en Delta y se crea _delta_log con transacciones ACID. Paso 7: leemos desde Delta y mostramos time travel a versiones anteriores.

MOSTRAR EN PANTALLA:

- * Terminal: salida de python jobs/02b_spark_sql_delta_lab.py
- * Explorador: delta/lab/delta_ventas/_delta_log
- * Terminal: salida de python jobs/07_delta_time_travel.py (historial versiones)
- * Diapositiva 8 Canva: pasos 5 al 7

BLOQUE 7 - Analisis gerencial (2 min) | Canva: diapositiva 9 preguntas

TEXTO PARA DECIR:

Respondemos las 4 preguntas de negocio con PySpark: cliente con mayor volumen de compra; top 10 ventas por importe; promedio de venta por cliente; y clientes que concentran el 80 por ciento del ingreso (análisis Pareto).

MOSTRAR EN PANTALLA:

- * Diapositiva 9 Canva: Preguntas de análisis
- * Terminal: `python jobs/06_analisis_negocio.py` (mostrar las 4 respuestas)

BLOQUE 8 - Proyecto final y Power BI (3 min) | Canva: diapositiva 9 proyecto

TEXTO PARA DECIR:

El Lakehouse completo integra Bronze con tres formatos, Silver limpio, Gold analítico y dashboard Power BI. Gold se exporta a CSV en `output/` para el modelo PBIP. Procesamos miles de transacciones en tres capas Medallion.

MOSTRAR EN PANTALLA:

- * Archivo `jobs/run_pipeline.py`
- * Carpeta `output/`: `kpi_generales.csv`, `ventas_por_categoria.csv`, etc.
- * Power BI: panel Datos con 5 tablas
- * Power BI: dashboard con tarjetas KPI y gráficos
- * Diapositiva 9 Canva: Proyecto final RetailX (1M, 3 capas)

BLOQUE 9 - Cierre (1 min)

TEXTO PARA DECIR:

En resumen implemente un Lakehouse RetailX con fuentes heterogéneas, pipeline Medallion, Spark y Delta Lake, análisis gerencial, time travel y consumo en Power BI. El código está en `data-lakehouse/lakehouse`. Gracias por ver el video.

MOSTRAR EN PANTALLA:

- * Diapositiva 5 Canva (Medallion) como cierre visual
- * Árbol completo del proyecto
- * Dashboard Power BI final

ANEXO - Comandos para la demo

```
$ cd data-lakehouse/lakehouse  
$ docker compose up -d  
$ docker exec -it retailx_dataops_spark bash  
$ python jobs/run_pipeline.py --rows 10000  
$ python jobs/06_analisis_negocio.py  
$ python jobs/07_delta_time_travel.py
```